

Pipeline ETL para Data Mart Académico

Erick Gutiérrez Sánchez - 202123377

1. Introducción y Alcance del Proyecto

El presente documento detalla la arquitectura y el flujo de trabajo del *pipeline* de Extracción, Transformación y Carga (ETL) diseñado para construir un Data Mart académico. El propósito fundamental es consolidar la información heterogénea de horarios y recursos educativos en una base de datos relacional (MySQL) para habilitar el análisis multidimensional (OLAP).

El alcance se centra en la integración de datos de cursos, profesores, aulas y horarios, estableciendo una única fuente de verdad para la toma de decisiones basada en la ocupación y distribución de recursos.

2. Plataforma Tecnológica y Stack de Desarrollo

El pipeline fue construido íntegramente en el lenguaje de programación Python. La elección de librerías se basó en su robustez para cada fase del proceso. Para la Extracción, se empleó *pdfplumber*, esencial para manejar la naturaleza tabular de los documentos de origen. La fase de Transformación se centralizó en *pandas*, aprovechando sus capacidades de manipulación, limpieza y normalización de *DataFrames*. Finalmente, la fase de Carga utiliza *SQLAlchemy* como una capa de abstracción para gestionar la conexión y asegurar la inserción segura de los datos en el backend de MySQL.

3. Estrategia de Ingesta y Extracción de Datos Fuente

La ingesta comienza con la lectura de tres archivos PDF, los cuales contienen las asignaciones de horarios y la metadata de los recursos. La librería *pdfplumber* es crítica en esta fase, ya que su funcionalidad permite identificar y convertir las estructuras tabulares de cada página PDF en colecciones de datos manejables. Cada colección es inmediatamente transferida a un *DataFrame* para su procesamiento. Este enfoque asegura que los datos sean liberados de su formato no estructurado de origen para comenzar el proceso de normalización.

4. Normalización y Aplicación del Modelo Dimensional

La Transformación es la etapa más intensiva, donde los datos brutos se preparan para conformar un Esquema de Estrella. El proceso incluye una rigurosa limpieza de ruido, como la eliminación de caracteres de nueva línea y la normalización de espacios en campos textuales (por ejemplo, el nombre del profesor). Posteriormente, se crean Dimensiones Atómicas a través de la

desduplicación de atributos únicos, como materias, edificios y salones. Se generan Claves Subrogadas (identificadores enteros únicos) para cada dimensión, desacoplando la clave de negocio de la integridad referencial. Esto sienta las bases para el modelado, donde la información se organiza alrededor de una Tabla de Hechos sin Medida (Factless Fact Table) que registra la ocurrencia de cada asignación de curso.

5. Diseño del Esquema de Datos y Persistencia

El Data Mart se compone de múltiples tablas dimensionales y una única Tabla de Hechos. Las dimensiones (`dim_profesor`, `dim_materia`, `dim_edificio`, `dim_salon`, `dim_ubicacion`, `dim_dias`, `dim_duracion`, `dim_carrera`) encapsulan los atributos descriptivos y se cargan primero. Un punto a destacar es el campo del aula, el cual fue estandarizado en el código a `numero_salon` para coincidir con la convención del esquema físico de la base de datos, resolviendo una inconsistencia de nomenclatura. La Tabla de Hechos, denominada `tabla_hechos`, almacena únicamente las Claves Foráneas de las dimensiones, midiendo la asignación o el evento en sí. La persistencia final se realiza en la base de datos MySQL horarios utilizando el método `to_sql()` de pandas, empleando la estrategia de *append* para las inserciones.

6. Aseguramiento de la Calidad y Gobernanza de Datos

Se aplican controles rigurosos para garantizar la alta calidad de los datos en el Data Mart. Esto incluye la validación de la unicidad en los *DataFrames* dimensionales antes de la carga, y la verificación de la integridad referencial para asegurar que cada registro en la Tabla de Hechos se vincule correctamente a un registro existente en las dimensiones. Para manejar los casos de datos incompletos o nulos, se implementó una estrategia de manejo de valores desconocidos, asignando los registros sin un profesor identificado a un ID genérico predefinido, manteniendo así la integridad del modelo.

7. Mantenimiento y Control de Versiones

Este documento corresponde a la Versión 1.0.1 del proyecto. La versión inicial se centró en la implementación del flujo principal. La actualización a la versión 1.0.1 se enfocó en la corrección de errores de nomenclatura de columnas (como la estandarización del campo 'salon') y la robustez de la conexión a la base de datos. El *pipeline* está diseñado para ser modular, lo que facilita su extensión futura para incorporar nuevas fuentes de datos o adaptarse a cambios en el formato de los documentos originales con un mínimo impacto en el modelo de datos.